

МОСКОВСКИЙ ФИЗИКО-ТЕХНИЧЕСКИЙ ИНСТИТУТ
(НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ
УНИВЕРСИТЕТ)

Отчет по I. Этапу проекта
"Интеллектуальная система улучшения
изображений"

Выполнила:

Игнатова Мария М05-513е

6 апреля 2026 г.

1 Постановка задачи, требования и ограничения

1.1 Цель проекта

Разработать систему автоматического улучшения фотографий, которая будет встроена в веб-формы или мобильные приложения как кнопка «улучшить фото». Система должна корректировать яркость, контраст, цветовой баланс и насыщенность, но при этом строго сохранять содержание изображения: нельзя менять объекты, лица или геометрию кадра - только цвета и контраст.

Формально задача выглядит так: на вход подаётся RGB-изображение I размера $H \times W \times 3$, на выходе получается такое же по размеру изображение $I' = f(I)$, где f — обучаемое преобразование. Обучаемся на парах $(I_{\text{raw}}, I_{\text{expert}})$, где I_{expert} — профессиональная ретушь. Минимизируем разницу между предсказанием и экспертом, но при этом требуем, чтобы структура исходного фото не искажалась.

Ограничения жёсткие: пользователь не должен ждать дольше 0.5 секунды (это стандарт (Google Core Web Vitals, [INP](#)). Модель должна быть лёгкой — работать на обычном сервере или даже в браузере, потребляя тысячи параметров вместо миллионов. Именно поэтому выбор падает на 3D LUT (таблицы замены цветов): они дают скорость 5–50 мс/кадр [6], занимают всего десятки Кб и сохраняют геометрию изображения. На первом этапе проверяются классические методы OpenCV (гамма, баланс белого, CLAHE) как нижнюю границу.

2 Данные: источники, структура, объём, разбиение

В качестве источника используется бенчмарк [MIT-Adobe FiveK](#), созданный MIT CSAIL и Adobe в 2011 году. Датасет содержит 5000 RAW-файлов в формате DNG и для каждого из них — 5 независимых ретушей (эксперты А–Е) в 16-битном TIFF. Также есть CSV-файл с семантическими метками (сцена, освещение, время суток). Полный объём — около 350 ГБ, но для экспериментов достаточно сжатой версии в JPEG (примерно 2.4 ГБ).

Данные разбиваются стандартным образом: 3500 пар на обучение, 500 на валидацию и 1000 на тест. Поскольку в датасете пять разных стилей, мы фиксируем в качестве целевого эксперта С — он наиболее сбалансирован (умеренно затемняет, средняя насыщенность, высокая согласованность с другими экспертами). Перед обучением все изображения будут приведены к единому размеру (ресайз до 512×512 для обучения и до 1024×1024 для замера скорости).

3 Разметка / таргет

Целевая переменная — это ретушь эксперта С (между ними есть стилистические различия). На основе EDA видно, что все 5000 RAW имеют 5 соответствующих TIFF, а расхождение в размерах (RAW vs эксперт) в 97% случаев не превышает 50 пикселей — это легко исправляется ресайзом. Средняя согласованность между экспертами В, С, D составляет SSIM около 0.91, что задаёт естественный потолок для любой модели.

4 EDA и проверка качества данных

Анализ проведён на всех 5000 RAW. Сравнение средних значений показало, что эксперты делятся на «затемняющих» (A, B, C) и «осветляющих» (E, D). Все эксперты повышают контраст (с 54.6 у RAW до 58–59) и снижают насыщенность (с 84.6 у RAW до 66–79). Эксперт C имеет яркость 98.0 (близко к RAW), контраст 58.5 и насыщенность 79.5 — наиболее умеренный.

Семантический анализ выявил, что дневные сцены составляют 63%, ночных — лишь 10%, поэтому при обучении потребуется аугментация для тёмных фото. Искусственное освещение доминирует (79%), что хорошо для обучения коррекции цветовых сдвигов. Проблемы с экспозицией (пересвет или недосвет) затрагивают 61% изображений — датасет богат типичными дефектами. Клиппинг (необратимая потеря деталей) встречается у 7% для пересвета и 6% для недосвета, такие примеры сложны, но присутствуют.

На основе экстремальных значений яркости и цветового баланса выделены три типа плохих случаев: недосвет ($\text{brightness} < 80$), пересвет ($\text{brightness} > 120$) и цветовой сдвиг (разница $R-B > 10$ или < -10). Все эти дефекты представлены в датасете, что подтверждает его пригодность.

Версия	Яркость (μ)	Контраст (μ)	Насыщенность (μ)
RAW	103.7	54.6	84.6
A	88.0	58.7	75.1
B	98.1	55.3	66.0
C	98.0	58.5	79.5
D	105.7	59.2	69.6
E	112.9	58.1	71.5

Таблица 1: Средние значения метрик для RAW и экспертов A–E

Категория	Тип	Доля (%)
Время суток	День	62.8
	Сумерки	27.1
	Ночь	10.0
Освещение	Тёплое искусственное	56.3
	Холодное искусственное	22.8
	Естественное	20.9
Экспозиция	Нормальная	39.0
	Пересвет	35.4
	Недосвет	25.6
Клиппинг ($>5\%$ пикс.)	Пересвет	6.8
	Недосвет	6.1

Таблица 2: Распределение сценариев съёмки

5 Признаки и представления

Для LUT-модели входными признаками служат только пиксельные RGB-значения. Никакой дополнительной пространственной информации не требуется, потому что LUT приме-

няет одно и то же цветовое преобразование ко всем пикселям независимо. Это обеспечивает инвариантность к разрешению, минимальную вычислительную сложность и гарантированное сохранение геометрии.

6 Подходы и baseline

В качестве baseline были реализованы классические методы OpenCV: гамма-коррекция ($\gamma = 0.8$), автоматический баланс белого (метод серого мира), CLAHE (clipLimit=2.0), а также комбинированный пайплайн (баланс белого + CLAHE + повышение насыщенности). Валидация на 100 изображениях относительно эксперта C дала следующие результаты:

- RAW (исходный после конвертации DNG $\Rightarrow$ BGR) показал SSIM 0.665
- PSNR 19.1 дБ

Ни один из методов не превзошёл RAW, максимальный SSIM у баланса белого составил 0.661. CLAHE и auto_gamma ухудшили SSIM до 0.54–0.55. Следовательно, классические методы не способны приблизиться к профессиональной ретуши.

Для выбора основного подхода было проведено сравнение классики, CNN, GAN, диффузионных моделей и таблиц замены цветов (LUT). Критерии: качество (SSIM), скорость инференса, размер модели и сохранение идентичности. Классика быстра (менее 10 мс) и сохраняет идентичность, но качество низкое (SSIM 0.54–0.66).

Согласно работам [2, 3], CNN достигают SSIM 0.92–0.95, однако требуют 50–200 мс на CPU и 50–200 МБ памяти. GAN, например EnlightenGAN [4], дают SSIM 0.93–0.96, но работают дольше (более 100 мс), занимают около 500 МБ и склонны к артефактам. Диффузионные модели неприемлемы из-за времени инференса в несколько секунд на кадр и склонности к генерации новых деталей, что нарушает идентичность. LUT же, как показано в работе [5], обеспечивает SSIM 0.93–0.96 (на уровне CNN и GAN), скорость менее 5 мс, размер 1–5 МБ и полное сохранение идентичности. Поэтому для проекта выбран обучаемый 3D LUT (архитектура Zeng et al., 2020 [5] или её адаптация).

7 Метрики и протокол оценки

Для количественной оценки используются полные референсные метрики: PSNR, SSIM и LPIPS (перцепционное сходство). Дополнительно для цветокоррекции будет измеряться ΔE (CIEDE2000) в пространстве Lab. Обязательно фиксируются время инференса на CPU для разрешений 512×512 и 1024×1024 , а также размер модели в мегабайтах. Помимо цифр, планируется визуальное сравнение side-by-side (исходное RAW, предсказание модели, эксперт C) с особым вниманием к ночным сценам и случаям, где метрики расходятся с восприятием.

8 План этапа 2 (следующие шаги и ожидаемые результаты)

На втором этапе мы реализуем обучаемую 3D LUT. Датасет будет разделён случайным образом с фиксацией seed (42) на три части: 4000 пар для обучения (80%), 500 для валидации

(10%) и 500 для теста (10%). Стратификация по яркости обеспечит равное представление тёмных и светлых снимков. Каждая пара состоит из RAW (вход) и ретуши эксперта С (цель). Все изображения приводятся к разрешению 512×512 при обучении (для скорости) и 1024×1024 при финальной оценке, нормализуются в диапазон $[0,1]$.

Архитектура LUT будет состоять из небольшой свёрточной сети (backbone), которая предсказывает веса для интерполяции между вершинами 3D-таблицы размера $33 \times 33 \times 33$. Функция потерь комбинирует L1-расстояние, SSIM-лосс и регуляризацию гладкости таблицы. Гиперпараметры (learning rate, batch size, коэффициенты в лоссе) будут подобраны по валидационной выборке.

После обучения мы сравним модель с baseline (классические методы) по SSIM, PSNR, LPIPS, ΔE , времени инференса и памяти. Ожидается, что LUT достигнет SSIM выше 0.85 (значительное улучшение по сравнению с 0.66 у RAW), при этом скорость составит менее 50 мс на изображение 1024×1024 , а размер модели не превысит 5 МБ. Дополнительно проведём визуальный анализ на тестовой выборке, особо выделяя кадры с недосветом, пересветом и сильным цветовым сдвигом. Все эксперименты будут задокументированы (seed, параметры препроцессинга, логи обучения) для полной воспроизводимости.

9 Заключение

В первом этапе выполнена полная постановка задачи с учётом потенциальных реальных ограничений, собран и проанализирован датасет MIT-Adobe FiveK, проведён EDA (распределения яркости, контраста, насыщенности, семантическое покрытие), реализована валидация классических методов (ни один не превзошёл RAW), обоснован выбор LUT-подхода. Разработан план второго этапа, определены метрики и критерии успеха. Датасет признан пригодным, а выбранная архитектура - оптимальной для массового применения.

Список литературы

- [1] [MIT-Adobe FiveK Dataset](#), Hugging Face, 2023.
- [2] Chen, Y., Wang, Y., Kao, M., Chuang, Y. (2018). Deep Photo Enhancer: Unpaired Learning for Image Enhancement from Photographs with GANs. CVPR.
- [3] Gharbi, M., Chen, J., Barron, J. T., Hasinoff, S. W., Durand, F. (2017). Deep Bilateral Learning for Real-Time Image Enhancement. ACM Trans. Graph. (SIGGRAPH).
- [4] Jiang, Y., Gong, X., Liu, D., Cheng, Y., Fang, C., Shen, X., ... Wang, Z. (2019). EnlightenGAN: Deep Light Enhancement without Paired Supervision. arXiv:1906.06972.
- [5] Zeng, H., Cai, J., Li, L., Cao, Z., Zhang, L. (2020). Learning Image-Adaptive 3D Lookup Tables for High Performance Photo Enhancement in Real-Time. IEEE Transactions on Pattern Analysis and Machine Intelligence.
- [6] Kim et al., "Lightweight and Fast Real-time Image Enhancement via Decomposition of the 3D LUT," ICCV 2025. [Ссылка](#).